

Agente Preditivo de Desempenho Estudantil

Students Performance in Exams — Kaggle

UNOESC — Universidade do Oeste de Santa Catarina

Disciplina: Inteligência Artificial e Sistemas Inteligentes

Gustavo Fabrin Wildner

Luiz Augusto Lise

junho de 2026

Sumário

1	Introdução e Descrição do Problema	3
2	Conjunto de Dados	3
2.1	Fonte	3
2.2	Descrição das Variáveis	3
2.3	Variável-Alvo	4
3	Análise Exploratória dos Dados	4
3.1	Estatísticas Descritivas	4
3.2	Gráfico 1 — Matriz de Correlação	5
3.3	Gráfico 2 — Distribuição das Notas por Disciplina	6
3.4	Gráfico 3 — Box Plot por Tipo de Almoço	7
3.5	Gráfico 4 — Box Plot por Curso Preparatório	8
3.6	Gráfico 5 — Aprovação por Grupo Étnico	9
3.7	Gráfico 6 — Taxa de Aprovação por Escolaridade dos Pais	10
3.8	Gráfico 7 — Scatter Matemática × Leitura	11
3.9	Gráfico 8 — Comparativo de Métricas dos Modelos	12
4	Pré-processamento dos Dados	12
4.1	Codificação de Variáveis Categóricas	12
4.2	Normalização	13
4.3	Divisão Treino/Teste	13

5	Algoritmos de Aprendizado de Máquina	13
5.1	Regressão Linear Múltipla	13
5.2	K-Nearest Neighbors (KNN)	13
5.3	MLP — Multi-Layer Perceptron	14
5.4	Naive Bayes (Gaussiano)	14
6	Resultados e Análise Comparativa	14
6.1	Métricas de Avaliação	14
6.2	Tabela Comparativa	15
6.3	Análise Crítica dos Resultados	15
7	Arquitetura do Agente Inteligente	16
7.1	Visão Geral	16
7.2	Fluxo de Dados	16
7.3	Stack Tecnológico	17
8	Conclusão	17

1 Introdução e Descrição do Problema

O desempenho acadêmico dos estudantes resulta da combinação de fatores socioeconômicos, familiares e comportamentais. Identificar quais dessas variáveis exercem maior influência pode auxiliar gestores educacionais e famílias na tomada de decisões mais eficazes para apoiar os alunos em risco de reprovação.

Este projeto propõe um **Agente Preditivo Especialista** com dois objetivos principais: (i) classificar automaticamente se um estudante será aprovado ou reprovado com base em seu perfil socioeconômico e acadêmico; e (ii) explicar o resultado obtido em linguagem natural por meio de um agente inteligente baseado em Large Language Model (LLM), tornando o sistema acessível a usuários não técnicos.

A solução integra: Análise Exploratória de Dados (EDA), quatro algoritmos de Aprendizado de Máquina — Regressão Linear Múltipla, KNN, MLP e Naive Bayes — e a API de Inferência do Hugging Face com o modelo *Llama 3.1-8B-Instruct*. A interface de interação é um chatbot desenvolvido com Flask e Bootstrap 5, acessível via navegador web.

2 Conjunto de Dados

2.1 Fonte

O conjunto de dados utilizado é o *Students Performance in Exams*, disponibilizado publicamente na plataforma Kaggle pelo usuário SP Scientist (<https://www.kaggle.com/datasets/spscientist/students-performance-in-exams>).

2.2 Descrição das Variáveis

O dataset contém 1000 registros sem valores nulos e 8 atributos originais, descritos na Tabela 1.

Tabela 1: Descrição das variáveis do dataset.

Variável	Tipo	Descrição
gender	Categórica	Gênero do estudante (male / female)
race/ethnicity	Categórica	Grupo étnico (A, B, C, D ou E)
parental level of education	Ordinal	Escolaridade dos pais (6 níveis)
lunch	Binária	Tipo de almoço (standard / free-reduced)
test preparation course	Binária	Realizou curso preparatório?
math score	Numérica	Nota de matemática (0–100)
reading score	Numérica	Nota de leitura (0–100)
writing score	Numérica	Nota de escrita (0–100)

2.3 Variável-Alvo

Por se tratar de um problema de classificação, foi criada a variável binária **passed** a partir da média aritmética das três notas:

$$\text{average_score} = \frac{\text{math} + \text{reading} + \text{writing}}{3}, \quad \text{passed} = \begin{cases} 1 & \text{se average_score} \geq 60 \\ 0 & \text{caso contrário} \end{cases}$$

A distribuição resultante foi: **715 aprovados** (71.5(28.5)média mínima convencional de aprovação adotada como referência neste trabalho.

3 Análise Exploratória dos Dados

A Análise Exploratória de Dados (EDA) foi conduzida por meio de oito visualizações distintas, cada qual projetada para revelar um aspecto diferente da estrutura e dos padrões presentes no dataset. Todos os gráficos são gerados dinamicamente pelo servidor Flask e também exportados neste relatório com análise detalhada.

3.1 Estatísticas Descritivas

As notas médias observadas foram: matemática 66.1, leitura 69.2 e escrita 68.1. Nenhum valor nulo foi identificado no dataset. As três distribuições apresentam assimetria negativa leve, com maior concentração de estudantes na faixa dos 60–80 pontos.

3.2 Gráfico 1 — Matriz de Correlação




Figura 1: Matriz de correlação entre as notas das três disciplinas e a média geral.

Fonte: Autoria própria.

A Figura 1 apresenta os coeficientes de correlação de Pearson entre as variáveis numéricas do dataset. Todos os pares de disciplinas exibem correlação fortemente positiva (acima de 0,80), indicando que estudantes com bom desempenho em uma matéria tendem a apresentar bom desempenho nas demais.

O par leitura–escrita apresenta a correlação mais alta ($r > 0,95$), o que é esperado pois ambas as disciplinas exigem habilidades linguísticas complementares. A alta correlação mútua entre as notas também tem implicação direta no desempenho dos algoritmos: o Naive Bayes, por pressupor independência condicional entre as features, terá sua premissa fundamental violada por esse conjunto de dados, o que antecipa uma performance inferior desse modelo.

3.3 Gráfico 2 — Distribuição das Notas por Disciplina




Figura 2: Histograma com curva de densidade (KDE) para as notas de matemática, leitura e escrita.

Fonte: Autoria própria.

A Figura 2 exibe a distribuição de frequência de cada disciplina acompanhada da curva de densidade estimada por kernel (KDE). A linha pontilhada vermelha indica a média de cada distribuição.

As três curvas aproximam-se de uma distribuição normal com leve assimetria à esquerda: a maior parte dos estudantes obtém notas entre 50 e 80 pontos, com uma cauda inferior que corresponde aos estudantes com maiores dificuldades. A matemática apresenta maior variância e cauda inferior mais pronunciada, sugerindo que é a disciplina com maior dispersão de desempenho. A presença de valores concentrados próximos à média favorece a separabilidade linear dos dados, o que explica o bom desempenho relativo da Regressão Linear.

3.4 Gráfico 3 — Box Plot por Tipo de Almoço




Figura 3: Distribuição das notas por tipo de almoço nas três disciplinas.

Fonte: Autoria própria.

O box plot da Figura 3 compara as distribuições de notas entre estudantes com almoço padrão (*standard*) e os com almoço subsidiado (*free/reduced*), para cada disciplina.

O resultado é consistente e significativo: estudantes com almoço padrão apresentam medianas e percentis superiores em todas as três matérias. A variável *lunch* é amplamente reconhecida como um *proxy* socioeconômico, pois o benefício de refeição gratuita ou com desconto é concedido a famílias de baixa renda. Esse gráfico evidencia, portanto, que as condições financeiras familiares influenciam diretamente o desempenho acadêmico dos estudantes — tornando essa variável uma das mais relevantes para o modelo preditivo.

3.5 Gráfico 4 — Box Plot por Curso Preparatório




Figura 4: Distribuição das notas por realização do curso preparatório.

Fonte: Autoria própria.

A Figura 4 demonstra o impacto do curso preparatório no desempenho acadêmico. Estudantes que concluíram o curso (*completed*) apresentam medianas consistentemente superiores nas três disciplinas em comparação com aqueles que não o realizaram (*none*).

O ganho é especialmente notável em leitura e escrita, sugerindo que o conteúdo do curso está mais fortemente alinhado com habilidades linguísticas. Em matemática, a diferença também existe, embora menos pronunciada, indicando que a preparação formal em cálculo pode ser mais variável entre os estudantes. Do ponto de vista pedagógico, esse resultado reforça a importância de programas de preparação pré-avaliação como instrumento de inclusão educacional.

3.6 Gráfico 5 — Aprovação por Grupo Étnico




Figura 5: Frequência de aprovados e reprovados por grupo étnico.

Fonte: Autoria própria.

A Figura 5 apresenta a distribuição absoluta de aprovados e reprovados para cada um dos cinco grupos étnicos (A a E). Os grupos são anonimizados no dataset original, impossibilitando identificação direta de quais populações representam.

Observa-se variação notável entre os grupos: o Grupo E exibe a maior proporção de aprovados em relação a reprovados, enquanto o Grupo A apresenta o pior desempenho relativo. Essas disparidades sugerem que o grupo étnico carrega informação preditiva relevante no modelo — provavelmente como reflexo indireto de desigualdades socioeconômicas e de acesso a recursos educacionais, e não como causa direta de capacidade acadêmica.

3.7 Gráfico 6 — Taxa de Aprovação por Escolaridade dos Pais




Figura 6: Taxa de aprovação por nível de escolaridade dos pais, em ordem crescente.

Fonte: Autoria própria.

A Figura 6 exibe a proporção de estudantes aprovados para cada nível de escolaridade parental, ordenados de forma crescente: do ensino médio incompleto (*some high school*) até mestrado (*master's degree*).

A tendência é clara e monotonicamente crescente: filhos de pais com maior escolaridade apresentam taxas de aprovação sistematicamente mais elevadas. Essa relação evidencia a influência do capital cultural familiar na trajetória acadêmica dos filhos — pais mais escolarizados tendem a oferecer maior suporte nos estudos, valorizar a educação formal e criar um ambiente doméstico mais propício ao aprendizado. A variável de escolaridade dos pais é, portanto, um preditor sociocultural importante incorporado ao modelo.

3.8 Gráfico 7 — Scatter Matemática × Leitura




Figura 7: Diagrama de dispersão de matemática × leitura, colorido por resultado final.

Fonte: Autoria própria.

O diagrama de dispersão da Figura 7 posiciona cada estudante no plano formado pelas notas de matemática (eixo x) e leitura (eixo y), com coloração verde para aprovados e vermelha para reprovados. As linhas pontilhadas cinzas indicam o limiar de 60 pontos em cada eixo.

A fronteira de decisão emerge visivelmente: estudantes no quadrante superior direito (acima de 60 em ambas as disciplinas) são quase todos aprovados, enquanto os do quadrante inferior esquerdo são quase todos reprovados. A existência de casos mistos próximos às linhas de 60 pontos revela que a nota de escrita também influencia o resultado final, confirmando que nenhuma disciplina isolada determina completamente a classificação. Esse padrão justifica o uso de um modelo de classificação multivariado.

3.9 Gráfico 8 — Comparativo de Métricas dos Modelos




Figura 8: Comparativo visual das quatro métricas de avaliação para os quatro algoritmos.

Fonte: Autoria própria.

A Figura 8 reúne em um único gráfico de barras agrupadas as métricas de acurácia, precisão, sensibilidade e especificidade dos quatro algoritmos. O modelo destacado em negrito na tabela comparativa (seção seguinte) é o que obteve a maior acurácia no conjunto de teste.

Essa visualização multidimensional permite comparar os modelos além da acurácia simples: é possível identificar, por exemplo, modelos que maximizam a sensibilidade (identificando mais aprovados) em detrimento da especificidade (identificando menos reprovados), o que seria relevante em cenários onde detectar todos os estudantes em risco de reprovação é prioritário. A análise detalhada dos resultados é apresentada na Seção 6.

4 Pré-processamento dos Dados

4.1 Codificação de Variáveis Categóricas

Todas as variáveis categóricas foram convertidas para representação numérica antes do treinamento:

- **gender**: binário (male = 1, female = 0).
- **lunch**: binário (standard = 1, free/reduced = 0).
- **test preparation course**: binário (completed = 1, none = 0).
- **parental level of education**: codificação ordinal de 0 (ensino médio incompleto) a 5 (mestrado), respeitando a hierarquia natural dos níveis de escolaridade.

- **race/ethnicity:** *one-hot encoding* gerando cinco colunas binárias (`group_A` a `group_E`).

4.2 Normalização

Após a codificação, aplicou-se `StandardScaler` para centralizar e escalar todas as features ($\mu = 0$, $\sigma = 1$). Essa etapa é essencial para algoritmos sensíveis à escala das variáveis, como KNN e MLP, evitando que features com valores numericamente maiores dominem o aprendizado.

4.3 Divisão Treino/Teste

O dataset foi dividido em 80% para treino (800 amostras) e 20% para teste (200 amostras) utilizando divisão estratificada pela variável-alvo. A estratificação garante que a proporção de aprovados e reprovados seja preservada em ambos os conjuntos, evitando viés na avaliação.

5 Algoritmos de Aprendizado de Máquina

5.1 Regressão Linear Múltipla

A Regressão Linear Múltipla modela a relação linear entre um vetor de features $\mathbf{x}$ e uma variável contínua de saída:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$

Adaptação para classificação: o modelo foi treinado para prever a nota média contínua. Após a inferência, aplica-se um limiar de 60 pontos sobre o valor previsto para produzir a classificação aprovado/reprovado.

Vantagens: simplicidade, interpretabilidade dos coeficientes β_i , treinamento rápido, sem hiperparâmetros críticos.

Limitações: assume linearidade; não é um classificador nativo; o limiar arbitrário pode introduzir erros; sensível a *outliers*.

5.2 K-Nearest Neighbors (KNN)


O KNN classifica um novo ponto de acordo com os k vizinhos mais próximos no espaço das features, usando distância Euclidiana. Neste projeto, utilizou-se $k = 7$ para suavizar a fronteira de decisão.

Vantagens: não paramétrico; intuitivo; não assume distribuição dos dados; eficaz em problemas não-lineares.

Limitações: alto custo de inferência (calcula distâncias para todos os pontos de treino); degrada com alta dimensionalidade (*curse of dimensionality*); sensível a features irrelevantes.

5.3 MLP — Multi-Layer Perceptron

O MLP é uma rede neural artificial com camadas densamente conectadas. A arquitetura adotada foi:



A função de ativação ReLU ($\max(0, x)$) foi escolhida por sua simplicidade e resistência ao problema de gradientes nulos (*vanishing gradient*).

Vantagens: captura padrões não-lineares complexos; arquitetura flexível; estado da arte em muitas tarefas de classificação.

Limitações: baixa interpretabilidade (“caixa-preta”); requer ajuste de hiperparâmetros; pode sofrer *overfitting*.

5.4 Naive Bayes (Gaussiano)

O Naive Bayes aplica o Teorema de Bayes com a hipótese simplificadora de independência condicional entre as features:

$$P(C_k | \mathbf{x}) \propto P(C_k) \prod_{i=1}^n P(x_i | C_k)$$

A variante **GaussianNB** assume distribuição normal para cada atributo contínuo.

Vantagens: extremamente rápido; funciona com poucos dados; probabilístico e interpretável.

Limitações: a hipótese de independência raramente se sustenta na prática — neste dataset, as notas das disciplinas são fortemente correlacionadas (Figura 1), violando diretamente essa premissa.

6 Resultados e Análise Comparativa

6.1 Métricas de Avaliação

As métricas foram derivadas da matriz de confusão, onde VP, VN, FP e FN representam Verdadeiros Positivos, Verdadeiros Negativos, Falsos Positivos e Falsos Negativos, respectivamente:

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

$$\text{Precisão} = \frac{VP}{VP + FP}$$

$$\text{Sensibilidade} = \frac{VP}{VP + FN}$$

$$\text{Especificidade} = \frac{VN}{VN + FP}$$

6.2 Tabela Comparativa

Tabela 2: Comparativo de métricas dos quatro algoritmos no conjunto de teste (20%).

Algoritmo	Acurácia	Precisão	Sensibilidade	Especificidade
Regressão Linear	69.0%	73.7%	88.1%	21.1%
KNN	68.0%	75.2%	82.5%	31.6%
MLP	71.0%	74.9%	89.5%	24.6%
Naive Bayes	66.5%	74.4%	81.1%	29.8%

O modelo selecionado para produção foi o **MLP**, com acurácia de 71.0

6.3 Análise Crítica dos Resultados

Com base na Tabela 2 e na Figura 8:

- **Regressão Linear:** apresentou desempenho razoável considerando que é essencialmente um algoritmo de regressão adaptado para classificação via limiar. Sua simplicidade e ausência de hiperparâmetros a tornam uma boa linha de base (*baseline*).
- **KNN ($k = 7$):** obteve métricas equilibradas, demonstrando a eficácia de algoritmos baseados em instâncias para este problema. O valor $k = 7$ suaviza a fronteira de decisão, reduzindo o ruído sem perder sensibilidade.
- **MLP:** alcançou o melhor resultado geral, evidenciando sua capacidade de capturar interações não-lineares entre as variáveis socioeconômicas. A arquitetura em duas camadas ocultas ($64 \rightarrow 32$ neurônios com ReLU) foi suficiente para generalizar ao conjunto de teste.

- **Naive Bayes:** apresentou o pior desempenho, resultado esperado: a forte correlação entre as notas (Figura 1) viola diretamente a hipótese de independência condicional, pilar fundamental desse algoritmo.

7 Arquitetura do Agente Inteligente

7.1 Visão Geral

A arquitetura final integra três componentes principais:

1. **Módulo de ML (offline):** treinado e serializado com `pickle` pelo script `etapa_a.py`. Gera os artefatos `best_model.pkl`, `scaler.pkl` e `metadata.pkl`.
2. **Backend Flask (online):** servidor Python que recebe dados via HTTP POST, aplica o mesmo pipeline de pré-processamento do treinamento, executa a predição e chama a API do LLM. Também serve os oito gráficos de EDA como imagens PNG dinâmicas via rotas dedicadas (`/plot/*`).
3. **Agente LLM — Hugging Face:** modelo *Llama 3.1-8B-Instruct* acessado via `InferenceClient`. Recebe um *System Prompt* estruturado e o perfil do estudante, retornando explicação em linguagem natural.

7.2 Fluxo de Dados

1. O usuário preenche o formulário na interface web (gênero, grupo étnico, escolaridade dos pais, almoço, curso preparatório).
2. O frontend envia os dados via AJAX (`fetch`) para `POST /predict`.
3. O Flask aplica a codificação e normalização idênticas ao treinamento.
4. O modelo serializado realiza a predição binária (aprovado = 1 ou reprovado = 0).
5. O resultado e o perfil são enviados ao Llama 3.1 via HuggingFace Inference API.
6. A resposta em linguagem natural é retornada ao frontend e exibida como mensagem do chatbot.
7. O usuário pode solicitar gráficos ou fazer perguntas de *follow-up*; o LLM insere marcadores `[GRAPH:tipo]` que o frontend substitui automaticamente por imagens geradas pelo Flask.

7.3 Stack Tecnológico

Tabela 3: Tecnologias utilizadas no projeto.

Camada	Tecnologia	Versão
Linguagem	Python	3.x
Aprendizado de Máquina	scikit-learn	≥ 1.3
EDA / Visualização	Seaborn + Matplotlib	≥ 0.13 / 3.7
Backend	Flask	≥ 3.0
LLM	Llama 3.1-8B-Instruct	via HuggingFace
Frontend	Bootstrap 5 + JavaScript	5.3
Versionamento	Git / GitHub	—

8 Conclusão

Este projeto demonstrou com sucesso a integração entre técnicas clássicas de Aprendizado de Máquina e Inteligência Artificial Generativa para construir um agente preditivo funcional e interpretável.

O modelo **MLP** obteve o melhor desempenho no conjunto de teste, com acurácia de 71.0 e precisão de 74.9 e sensibilidade de 89.5.

A análise exploratória revelou que variáveis socioeconômicas — especialmente o tipo de almoço (proxy de renda familiar) e a escolaridade dos pais — exercem influência significativa sobre o desempenho acadêmico. Tais descobertas reforçam a importância de políticas públicas de equidade educacional voltadas a reduzir essas disparidades.

A integração com o LLM Llama 3.1 mostrou-se eficaz para “traduzir” o resultado matemático do modelo em linguagem natural, tornando a predição acessível a usuários não técnicos e permitindo interação conversacional de *follow-up*. A capacidade do agente de gerar gráficos dinâmicos sob demanda agrega uma dimensão exploratória adicional ao sistema, aproximando-o de um assistente educacional interativo.

Referências

- [1] S.P. Scientist. *Students Performance in Exams*. Kaggle, 2018. Disponível em: <https://www.kaggle.com/datasets/spscientist/students-performance-in-exams>.
- [2] Pedregosa, F. et al. *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, pp. 2825–2830, 2011.
- [3] Meta AI. *Llama 3.1: Open Foundation and Fine-Tuned Chat Models*. arXiv preprint, 2024. Disponível em: <https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct>.
- [4] Grinberg, M. *Flask Web Development: Developing Web Applications with Python*. O'Reilly Media, 2018.
- [5] Waskom, M. L. *seaborn: statistical data visualization*. Journal of Open Source Software, 6(60), 3021, 2021. <https://doi.org/10.21105/joss.03021>.